

ImpactKV 论文逻辑与图表速览

给改稿用，不是投稿稿。数字只复述当前 `main.tex` 已发表、且 RESULT 为 COMPLETE 的战役。投稿：ASPLOS 2027, `sigplan,anonymous,review,nonacm`，正文 11 页。题目： *ImpactKV: Coding-Aware Lossy KV Reuse for Shifted File-Island Prefill* 评测范围写死： **sequential one-token prefill**，不是 serving 皇冠。

0. 一句话

编码 agent 会在不同 **prompt** 位置重读同一份仓库文件：token ID 相同，RoPE 相位和左右上下文不同。前缀缓存因此 miss。ImpactKV 的贡献不是「再拷多一点 token」，而是：

1. 从 agent 协议里**决定哪些文件岛可以近似** (admit: 单文件、版本有效、token-ID 相同、 $\Delta \neq 0$)。
2. 在引擎里把这些岛做成 **fail-closed 的 true-lossy 拷贝** (source 侧预旋转 K , V 原样；机械失败则整岛 Dense)。
3. Headline 只报 **cache-ready TTFT** (source KV 已在)，对比同一引擎的 Dense。

Headline 只证明 7B、M0+M2、prefetch/prefix 都关。 30B 是第二个 serving point，只在附录。

1. 冻结合同（改稿红线）

改正文、改图、改 caption 时不要碰这些：

项	冻结值	备注
7B 作业	137185 COMPLETE	Qwen2.5-Coder-7B-Instruct
Headline	1.492 $\times$ / 99.3% / 93.6% / 1684/1684	cache-ready; prefetch off; prefix off
7B 均值长度	copied 1537 / prompt 4433	来自 7B MOTIVATION.json，不是 30B 的 1528/4403
30B 作业	96092 附录	1.375 $\times$, agree 94.8% , 1684/1684
3B probe	suffix TV 0.00264 , formation 0.0462 , top-10% 80.1%	不是 7B/30B TTFT，不当 admit 门
不要写	N=4 的 0.905/0.841, <code>tab:nuse</code> , SOTA、7B 正文里的 96.5%	N=4 只留在 RESULT.json
不要绑	1.492 $\times$ 与 1.375 $\times$ 写在 80 字符内	两套 checkpoint，不是一个 official method
不要把	30B 速度 和 另一模型族 official Accuracy 合成一张主表	
检查	<code>cd paper_swebench_ucm && python3 scripts/check_asplos_claims.py</code> 必须 PASS	

Headline 协议：source KV 已在、decode 一个 token、对比自己的 Dense。One-token agreement **不是** SWE-bench resolved。

2. 论证链（论文必须按这个顺序）

系统论文叙事，不是「先堆实验」：

1. **Background**：今天的 KV 管理（精确前缀 / 泛 lossy copier / 生命周期）+ **Limitation**。
2. **Motivation**：编码任务结构 $\rightarrow$ 折线/热力图 $\rightarrow$ **Opportunities**（三条）。

3. **Design**: 总架构图, 然后 **M0** (admit 编译器, 带图)、**M2** (lossy copy, 带图)。
4. **Implementation**: SGLang 集成、manifest、精确 prompt 回放。
5. **Evaluation**: Setup → Overall (两个 checkpoint, 不混成一种方法) → 逐模块 ablation → Sensitivity。

`main.tex` 的 `\input` 顺序必须是: introduction → background → motivation → problem → template → kv-management → implementation → evaluation。

3. 问题: 要复用的东西不在前缀上

多角色编码 (planner / implementer / tester / reviewer)。后一个角色重读前一个角色已经编过的 `repository_code`。中间插了 tool observation, 文件起点从 s 变成 t 。

定义 $\Delta = t - s$ 。

- $\Delta = 0$ 且左边字节也相同 → radix / prefix cache。不是本文 (CacheWise 答的是这个)。
- $\Delta \neq 0$ 且 token ID 相同 → **true-lossy**: token 精确, 激活近似。这是本文。

计划时丢掉 48 个零位移岛, 防止实验退化成前缀缓存。




图 1: 编码角色在移位下标重读同一文件模块。论文 fig:dag-example

4. Background: 现有系统答的是另一个问题

系统	答的问题	为什么不够
PagedAttention / SGLang radix / LMCache / KVFlow / CacheWise	精确前缀共享、调度、驱逐	要求 $\Delta = 0$ 和共享左上下文
CacheBlend / KVCOMM / RelayCaching	尽量多拷、再修一部分	不知道哪些 coding span 可以近似
Continuum / Tokencake	TTL / 作业调度	保留 文件级 admit
CacheSlide / RedKnot / KVLink / Notes-at-Prefill	已知 Δ 下旋转 K	旋转是 copy 实现, 不是文件白名单

Limitation (论文必须有这一小节): 精确前缀 miss 移位文件; 泛 copier 不管哪些文件可以近似; 拷 K/V 跨 $\Delta \neq 0$ 是 true-lossy, 目前没有编码协议当 admit 规则。

RoPE 旋转本身不声称 novelty。ImpactKV 用同一闭式 R_Δ , 差别在 哪些 span 可以进 lossy 路径。

5. Motivation: 编码结构可以指导 KV

轨迹来自 24 个 Verified 任务的 live-agent (rolling-6, 28K cap)。这是评测底物, 不是 official Accuracy。

5.1 前缀缓存拿不到的互补复用

7B PLAN (作业 137185 token, 无新 GPU):

- 每组都有非空 radix LCP 并且 有移位文件岛 (235/235)。
- 均值 LCP **24.7%** (1047 tok.); 文件岛 **33.4%** (1537 tok.)。
- 两套 token **不相交** (overlap = 0, LCP 到不了第一座岛)。
- 无约束 KVCOMM 式拷贝额外搬走 **194,624** token (campaign total, 不是每组), 235/235 组都有。这些是 tool log / 命令 / assistant 包在文件岛周围的上下文, 不是第二份合法仓库文件。




图 2: 上: LCP vs 文件岛占比 (235 组)。下: file-module vs 无约束拷贝。论文 fig:motivation-coverage / fig:motivation-extra

5.2 损失落在哪 (3B probe, 不是 7B/30B 注意力)

7B 速度战役不记 **attention**。另开 Qwen2.5-Coder-3B 探针:

- 26 岛: suffix TV **0.00264**, next-action **0.00492**, source-time formation **0.0462** (大约高一个数量级; 约 4.4% formation 质量在 target 前缀没有对应物)。
- 20 条 Dense prompt: top-10% key 吃掉 **80.1%** 质量; 观察内 top-20% 为 **80.2%**。
- 同一 8 条 prompt: file-module module TV **0.00214** vs CacheBlend **0.0454** vs KVCOMM **0.0745** (局部 TV, 不是 Accuracy)。

推理方向: 默认修后缀 (CacheBlend 式) 是错的 repair; 该修的是岛在 source 前缀下形成的 K 相位 $\rightarrow$ M2 做 source 侧 K 预旋转, 而不是 suffix recompute。

硬边界: 编译器 **does not estimate Attention**。TV 不进主表, 不绑 $1.492\times / 1.375\times$ 。




图 3: 26 岛 suffix / next-action / formation TV。论文 fig:tv-locus




图 4: 同一 8 条 prompt 的 module TV。论文 fig:module-tv




图 5: 下一动作注意力质量热力图。file-module 跟 Dense; CacheBlend/KVCOMM 偏 system 和 tool。
论文 fig:attn-heatmap




图 6: K/V 相对 Dense 的 cosine drift。file-module 漂移限在拷贝的代码岛。论文 fig:kv-heatmap




图 7: Dense 注意力稀疏性: top token 比例 vs 质量。论文 fig:attn-proxy

5.3 Opportunities (三条, 直接变成 Design)

1. **Admit** 移位文件, 不是整段 **prompt**。拷 33.4% 合法文件岛, issue / tool / 过期文件走 Dense。
2. 修 K 相位, 不要重算 **suffix**。Formation TV $\sim 17 \times$ suffix TV。
3. 机械失败则整岛 **fail-closed**。多拷那 194,624 extra token 更快、更不一致, 那不是本政策。

6. Design: 四个模块，Headline 只用两个

在线路径: Dense prefix $\rightarrow$ M2 拷贝已 admit 的岛 $\rightarrow$ Dense remainder $\rightarrow$ 1-token decode。

模块	作用	Headline 137185
M0 编译器	冻结轨迹 $\rightarrow$ PLAN: hash、 (s, t, L) 、 $\Delta \neq 0$	开
M1 前缀复用	radix LCP, 不拷岛	关
M2 lossy 拷贝	$K \leftarrow R_{\Delta} K$, V 原样; 机械失败则 Dense	开
M3 prefetch	later-roles 驻留提示; miss $\rightarrow$ M2	关

关 M1/M3 的原因: 主表不能被 radix hit 或 prefetch 领功。M3 miss 必须退化成仍持有的 M2 拷贝, 不能把合法岛改成 Dense。




图 8: 引擎栈。Headline 只用 M0+M2。论文 fig:architecture

页身份: (source-prefix hash, content hash, Δ)。相同 token、不同左上下文或不同 Δ = 不同物理页。

7. M0: 文件模块 admit 编译器


不是让 LLM 给每个任务合成 DAG。离线 oracle: 重建精确 target token $\rightarrow$ 定位 repository_code $\rightarrow$ 过四道门:

1. 单文件 (一条 path)
2. 该 path 在轨迹里的版本仍有效 (编辑后不拷旧文件)

3. source/target token ID 在 span 上相同

4. $\Delta \neq 0$ (零位移丢掉)

产出: 235 组、421 岛 (丢掉 48 个零位移)。组内 1/2/3 岛 = 89 / 106 / 40。均值 copied 1537 / prompt 4433 (median 4239; p90 6759; max 8721)。




Offline oracle on frozen traces; not an LLM-synthesized DAG.

图 9: M0 离线编译流程。论文 fig:template-process


8. M2: true-lossy 文件岛拷贝

每座合格文件模块是一个物理岛。目标计算路径: Dense prefix, 拷每座岛, Dense remainder, 再 decode。租赁岛要么整段拷, 要么整段丢, 没有 partial serve。

Source prompt (index s)



Target prompt (index t)



Token IDs match; positions do not. Fail-closed if the copy is mechanically invalid.

图 10: 跨 turn 文件模块复用。只修 K 相位。论文 fig:kv-reuse

Fail-closed: hash 不匹配 / 覆盖不全 / 分配失败 → 丢岛、Dense 重算。Headline: 421 次 source 预旋转, 0 fallback。零 fallback 不是贡献, 也不能拿掉检查。

9. Evaluation

顺序必须是 **Setup** → **Overall** → **Ablation** → **Sensitivity**。正文评测图全部 \columnwidth, 禁止 figure*。

9.1 Setup

- 引擎 SGLang; 模型 Qwen2.5-Coder-7B-Instruct; 温度 0; decode 1 token; warmup 1 + 测 3 (235 × 3 = 705 对)。
- 作业 **137185**。Prefetch 和普通 prefix 关。
- 数据集: 24 任务 live-agent, **convenience sample**, 不是 500-task; 235 组是 rolling-6 **轮次**, 不是 235 个任务; 6 个仓库, 20/24 任务有合格组。
- 主基线: 同一引擎、同一 token 的 Dense。隔离: prefix-only / dual (139839); admit 克隆: KVCOMM-style / CacheBlend-style 15% 边界重算 (137400), **不是原生栈**。
- 不报** source-inclusive N -use。

两个 checkpoint 只报 agree + copy, 不把两个 speedup 写进同一张小表:

Checkpoint	Job	Agree	Copy
Qwen2.5-Coder-7B-Instruct	137185	93.6%	1684/1684
Qwen3-Coder 30B-A3B (AWQ)	96092	94.8%	1684/1684

9.2 Overall (只 7B 主表)

指标	Dense	ImpactKV
组 / 对	235 / 705	235 / 705
拷贝 / fallback	—	1684/1684 / 0
Mean TTFT	585.9 ms	392.7 ms
Median / p90 / p99	555 / 952 / 1178	383 / 586 / 819
Cache-ready	1.000×	1.492×
成对节省 (均/中)	—	30.6% / 27.9%
成对胜率	—	99.3%
One-token agree	—	93.6% (不是 resolved)

30B 附录：1.375×，94.8%。不要写进 Table 7/8 主表。




图 11: 705 对 cache-ready TTFT 的 CDF。论文 fig:ttft-cdf




图 12: 每组 speedup vs 拷贝比例。Headline 不是短 prompt 伪迹。论文 fig:copied-speedup

9.3 Ablation

Prefix 隔离 (作业 139839, 同一 235 组 PLAN, prefetch 关)。Speedup 相对这次 Dense, 不混进主表。

Arm	vs Dense	Med. save	Agree	Prefix	Copy
prefix-only	1.526×	32.9%	100%	940	0
lossy-only	1.408×	23.7%	93.6%	0	1684
dual	2.120×	55.4%	94.9%	940	1126

文件模块在已有 prefix 上的增量是 $\text{dual/prefix-only} = 1.390\times$ ，同样不进主表。Dual 的 $2.120\times$ 不要和 $1.492\times$ 写在一起。




图 13: Prefix vs lossy 隔离。论文 fig:prefix-on

Admit 克隆（作业 137400，同一引擎，不是原生 CacheBlend/KVCOMM）。

Arm	vs Dense	Med. save	Win	Agree	Copy
File-module	$1.492\times$	27.9%	99.3%	93.6%	1684/1684
KVCOMM-style	$2.100\times$	50.9%	99.9%	89.4%	948/948
CacheBlend-style	$1.883\times$	45.6%	100%	91.9%	948/948

无约束更快，是因为多搬了 token；headline 留下文件门，是因为那 194,624 extra 不是合法仓库文件。51 对上 file 跟 Dense、KVCOMM 不跟（17 组 $\times$ 3 round）。不 full-decode 这 17 组。不跑 same-token 30B CacheBlend/KVCOMM。30B 上 greedy longest-span (132385) 不是比较对象（agree 94.8% $\rightarrow$ 87.1%）。




图 14: 同引擎 admit 克隆: 更快但更不一致。论文 fig:admit

9.4 Sensitivity (同一 705 对, 不是新 GPU)

Speedup 随 prompt 变长、岛变多、拷贝比例变高而变大; $|\Delta|$ 不是主因。

- 长度: $<3K$ $1.28\times \rightarrow 7K$ $1.97\times$
- 岛数: $1/2/3 = 1.315\times / 1.492\times / 1.833\times$
- 拷贝比例 $Q1 \rightarrow Q4$: $1.196\times \rightarrow 2.116\times$
- $|\Delta| \geq 3000$ 仍是 $1.609\times$

数值表在附录 (tab:prompt-shape / tab:ablate-islands / tab:ablate-delta / tab:ablate-frac)。




图 15: 四切分 speedup. 论文 fig:eval-slices

One-token 93.6% 的字段名叫 `not_accuracy`。Live-agent 24 任务 Dense 3/24 vs policy 5/24 (McNemar $p = 0.625$) 是轨迹生产者，不是本 replay，也不是 Accuracy 赢。

10. 附录里有什么（正文不要混进来）

- 七组 dual-island 隔离（不是 30B PLAN，不是主表）。
- 30B AWQ 回放 1.375×（作业 96092）。
- Template prefetch（作业 119795）：coding 1.390×、prefetch-only 0.996×、combined 1.392×。不要

把 **prefetch** 表当成 $1.492\times$ 方法。Hints 是 next-island / later-roles, 不是 remaining uses。

- 按仓库切片 (30B 派生, 不排名)。
- 7B sensitivity 数值表; fail-closed 机械计数图、岛数分布图。

11. 图表 文件 (改图改这里)

论文标签	文件	生成脚本 / 来源
fig:dag-example	figures/dag-example.tikz	手写 TikZ
fig:motivation-coverage / extra	figures/fig_motivation_coverage.png	scripts/build_motivation_heatmaps.py (7B PLAN + 137400 PLAN)
fig:tv-locus / module-tv / attn-proxy	figures/fig_tv_locus.png 等	同上 (3B frozen26 / four-arm / frozen20)
fig:attn-heatmap / kv-heatmap	figures/fig_attn_heatmap.png	冻结 3B four-arm PNG, 不要手改数字
fig:architecture	figures/architecture.tikz	手写 TikZ
fig:template-process	figures/template_process.tikz	手写 TikZ
fig:kv-reuse	figures/kv-reuse.tikz	手写 TikZ
fig:ttft-cdf / copied-speedup / prefix-on / admit / slices	figures/fig_*.png	scripts/build_7b_eval_figures.py (冻结 137185/139839/137400)
主表数字	sections/evaluation.tex	只许从 RESULT.json 抄, 禁止手改

正文: sections/*.tex。检查: scripts/check_asplos_claims.py。编译: bash compile.sh。

Motivation 节禁止再出现 `\begin{table}`。评测正文图必须 `\columnwidth`。

12. 改稿时常见杀伤

- 把 cache-ready $1.492\times$ 说成冷启动 wall-clock 或 $N=1$ 服务加速。
- 把 93.6% one-token 说成 Accuracy / resolved。
- 打开 prefix 或 prefetch 却把增益算给 coding-aware copy。
- 把 30B $1.375\times$ 写进 7B 主表, 或和 $1.492\times$ 并排当「一个方法两个规模」。
- 把 3B TV 和 7B/30B TTFT 绑在一起。
- 恢复 $N=4$ 账单 (0.905 / 0.841 / `tab:nuse`)。
- 写 SOTA。写「欠 500-task / 并发 P99 / 原生 CacheBlend 绝对值」。
- 用 `\vspace` 挤 11 页 (检查器会 FAIL)。

诚实的一句话: 编码感知的 true-lossy 文件模块复用, 是长多文件 agent prompt 上的 **cache-ready** 赢。它是 sequential one-token prefill vs 自己的 Dense, 不是并发 serving, 不是冷启动 wall-clock, 也不是 official SWE-bench resolved。