

ImpactKV 模板引导 Prefetch (M3) 算法汇报

ImpactKV / ASPLOS 2027

2026-08-26

本报告说明 **M3 模板引导 prefetch**: 它做什么、不做什么、如何与 M0/M2 接口、顺序 one-token 评测上为什么不是加速、以及 headline 为何关掉它。数字来自冻结战役, 禁止改作业 137185 / 96092 的 RESULT.json。

目录

1 一句话结论	1
2 问题: 驻留 $\neq$ 准入	1
3 接口: M3 不扩大拷贝集合	2
4 算法	2
4.1 Hint 编译 (next-island / later-roles)	2
4.2 调度与加载	3
4.3 Miss 语义 (必须)	3
5 运行时路径	3
6 实验 (冻结数字, 禁止手改 RESULT)	4
6.1 作业 119795: 235 组顺序 1-token (30B PLAN, 附录)	4
6.2 7 组 dual-island (作业 124825–124829)	4
7 为何 Headline 关掉 M3	4
8 代码地图	5
9 汇报时建议强调的三句话	5
10 不要说的	5

1 一句话结论

M3 回答的是 **何时**、把已经 admit 的页放到哪一层 (device / host), 不回答哪些 span 可以拷。Admit 是 M0, 拷贝是 M2。顺序 1-token、source 已在 device 时, 没有重叠窗口, prefetch 不

能比「已经持有的拷贝」更快。Headline 7B（作业 137185, cache-ready 1.492 $\times$ ）把 M1 和 M3 关掉，主表不能被 radix 或 prefetch 领功。

模块	Headline 137185	职责
M0 编译器	开	离线 PLAN: 单文件、版本有效、token-ID 相同、 $\Delta \neq 0$
M1 前缀	关	radix LCP ($\Delta = 0$), 不拷岛
M2 拷贝	开	$K \leftarrow R_{\Delta}K$, V 原样; 失败则整岛 Dense
M3 prefetch	关	对已 admit 的页发驻留 hint; miss $\rightarrow$ 仍持有的 M2

2 问题：驻留 $\neq$ 准入

编码 agent 的 planner / implementer / tester / reviewer 会在滚动历史里反复读同一仓库文件。文件岛的 token ID 相同，位置不同 ($\Delta \neq 0$)。这带来两个独立问题：

1. **Admit (M0)**: 哪些 span 允许 true-lossy 拷贝。
2. **Residency (M3)**: 这些页现在在 host 还是 device; 下一次用之前要不要提前搬。

把两件事绑在一个开关里会出两类错: (i) prefetch 把不该拷的 tool log 搬上 GPU; (ii) prefetch miss 把本来已经 admit 的岛改成 Dense, 等于关掉 M2。第二条在 7 组 dual-island 战役上真实发生过: combined 相对 dual 变成 0.528 $\times$ (7 个 hint、4 次 miss 后 Dense)。**正确语义: miss 必须落到仍持有的 M2 拷贝, 不得 Dense 重算合法岛。**

3 接口：M3 不扩大拷贝集合

页键与 M2 相同：

(*source-prefix hash*, *content hash*, Δ).

Hint 只携带已存在的键、目标层、相对截止时间和优先级。**不旋转 K , 不改 admit 集合, 不估 Attention。**

实现上分两层编译器 (kvcomm_prefetch/template_hints.py):

- `compile_template_prefetch_hints`: 优先级 = 声明的剩余 use 次数 (oracle, 评测里不用它当 online 信号)。
- `compile_next_island_prefetch_hints`: **线上实际用的**。优先级 = 编码协议里的 **later-roles** (planner 读完通常还有 3 个下游角色), **不是** 未来 `target_uses`。

Skip 条件 (任一成立则不发 hint):

- 未过 M0 门 (非单文件、token-ID 不匹配、版本失效、 $\Delta = 0$ 的 MIDDLE)。
- `later_roles_in_protocol = 0` (协议上没有下游再读)。
- 页已经在 DEVICE 且 下一个 use 就是当前顺序请求: `no_overlap_window`。

最后一条解释了作业 119795 上 **Hints** = 0: 顺序 1-token、岛已在 device, 没有「提前搬」的时间窗。

4 算法

4.1 Hint 编译 (next-island / later-roles)

Algorithm 1: 编译 next-island prefetch hints (不扩大 admit 集)

Input: 已观察的 PREFIX / MIDDLE 岛 (协议信号, 不含未来 target_uses)

Output: 按优先级排序的 KVPrefetchHint

```

1 for each observation o do
2   if o 未过 admit 门 then
3     continue
4   if o 已在 DEVICE 且下一 use 即当前请求 then
5     continue // 无重叠窗
6   if o 是 MIDDLE 且 later-roles ≤ 0 then
7     continue
8   发 hint: (key, DEVICE, deadline, priority=later-roles)
9 按 (-priority, key) 排序去重

```

4.2 调度与加载

AsyncKVPrefetchScheduler 是截止时间 / 优先级堆 (相对 deadline_s 从提交时刻起算)。工作线程到期则标记 expired, 否则交给 KVPrefetchCoordinator:

1. 关核或关 prefetch → 直接 disabled。
2. 按 (deadline, -priority, key) 去重排序。
3. store.lookup(key): 没有页 → store_miss (不创造新岛)。
4. 已在目标层 → pin; 否则 ensure_resident 再 pin。

MiddleKVPrefetchAPI.export_middle_kv 可以把 device 切片备份到 host, 供稍后 prefetch 回 device。这是驻留搬运, 不是第二次 admit。

4.3 Miss 语义 (必须)

resolve_copy_source_after_prefetch(owned, prefetched) = prefetched 若非空, 否则 owned。

等待 hint 超时或 MiddleKVPrefetchError 时记 template_prefetch_miss, 然后仍用 owned handle 走 M2。返回空才允许 Dense。代码注释写明: 7 组 combined 的 4/28 fallback 把 dual 的 8.49× 打成 4.48×, 就是 miss 误走 Dense。

5 运行时路径




图 1: M3 不改 PLAN。它只给已存在的页发驻留提示。Headline 战役此路径关闭。
环境开关 (`template_prefetch_modes.py`):

模式	KVCOMM	LOSSY	PREFETCH
dense	0	0	0
prefix_only / lossy_only / dual	1	1	0
combined	1	1	1

combined 才打开 host overlap 与 `prefetch_spill_device`。Manifest 里 `prefetch_deadline_s=30`、`prefetch_wait_s=90`。prefix_only 把 `copy_middle=False`，只留 radix 前缀。

6 实验（冻结数字，禁止手改 RESULT）

6.1 作业 119795：235 组顺序 1-token（30B PLAN，附录）

同一 235 组、705 对。Hints 是 next-island / later-roles，不是 remaining uses。顺序下下一岛已在 DEVICE，hint 被 `no_overlap_window` 跳过。

臂	相对本战役 Dense	拷贝	Spill	Hints	Miss
Dense	1.000×	—	—	—	—
coding（仅拷贝）	1.390×	1684/1684	0	0	0
prefetch-only	0.996×	0	0	0	0
combined	1.392×	1684/1684	0	0	0

表 1: 作业 119795。combined $\approx$ coding，是开销不是 prefetch 加速。prefetch-only 不是拷贝赢。不要把此表当成 7B 主表 1.492×

要点：

- Dual 前缀 + 拷贝相对 Dense **不是** prefetch 数字。
- 119795 **不是** 96092（96092 是 30B 拷贝附录，1.375×，prefetch 关）。
- 论文 `tab:template-prefetch` 停在 119795。

6.2 7 组 dual-island (作业 124825–124829)

7 组、21 对。prefix-only $1.155\times$, lossy-only $4.526\times$, dual $8.490\times$ 。combined 发了 7 个 hint、4 次 miss, 随后 **Dense 了合法岛** (24/28 拷、4 fallback), 相对 dual 为 $0.528\times$ 。这是模块 bug, 不是「prefetch 更慢」的算法结论。当前 kvcomm_exact.py 已改成 miss $\rightarrow$ owned M2。验证需要**新目录**重跑, **禁止覆盖**上述冻结 RESULT。

7 为何 Headline 关掉 M3

顺序 cache-ready 协议 (source KV 已在、解 1 token、对同一引擎 Dense) 下:

- 下一岛已经在 device, prefetch 没有重叠窗。
- 打开 M3 却把增益算给 coding-aware copy, 审稿人会杀主表。
- 7 组上 miss $\rightarrow$ Dense 会把拷贝核弄脏。

因此作业 137185: prefetch off、prefix off、1684/1684、0 fallback、 $1.492\times$ 。M3 的论文位置是**附录驻留检查**, 不是速度声称。

8 代码地图

路径	角色
python/.../kvcomm_prefetch/template_hints.py	later-roles / next-island 编译
python/.../kvcomm_prefetch/scheduler.py	截止时间堆、过期
python/.../kvcomm_prefetch/coordinator.py	lookup / load / pin
python/.../kvcomm_prefetch/middle_kv.py	host 导出与回装
python/.../kvcomm_exact.py	miss $\rightarrow$ owned M2
benchmark/.../template_prefetch_modes.py	五模式开关
benchmark/.../run_swebench_template_prefetch.py	战役入口

单测 (无 GPU): kvcomm_prefetch/test_*.py, 含 test_prefetch_store_miss_does_not_copy、test_resolve_copy_source_after_prefetch_keeps_owned_on_miss。

9 汇报时建议强调的三句话

1. Prefetch 是**驻留**, 不是**准入**; hint 的键必须已经在 M0 白名单里。
2. 信号来自编码协议的 later-roles / next-island, **不是** remaining N -use, 也不是 Attention。
3. 顺序 1-token 上 combined $\approx$ copy ($1.392\times$ vs $1.390\times$), 不是加速; headline 关掉 M3, 避免主表被驻留模块领功。

10 不要说的

- 不要说 M3 贡献了 $1.492\times$ 。

- 不要把 119795 和 96092、137185 写成一个 official method。
- 不要报 N=4，不要写 SOTA，不要把 one-token agreement 叫 Accuracy。
- 不要把 7 组 $0.528\times$ 解释成「prefetch 算法更慢」而不提 miss→Dense bug。

冻结战役：119795 (`impactkv_swebench_template_prefetch_nextisland_20260821`)、7 组 dual-island (`..._7b_dualisland_20260822`)。引擎分支 `integration/template-prefetch-swebench`。接手说明见仓库根目录 `HANDOFF.md`。